

Abbiamo visto che il Gradient Descent aggiorna i parametri con

$$w_{k+1} = w_k - \eta \nabla C(w_k)$$


w è il vettore dei parametri e η è il learning rate.

La discesa del gradiente trova il minimo globale se la funzione è convessa.


Sfortunatamente, quasi tutti i problemi di ottimizzazione che sorgono nell'allenamento di reti neurali sono non convessi

- introducendo la non linearità nella rete (aggiungendo strati nascosti), la funzione costo diventa non convessa e compaiono i minimi locali

Consideriamo questa curva



Inizializziamo w ad un punto a ed applichiamo il metodo iterativo del gradiente.




w raggiunge il punto b e si ferma, poiché in b il gradiente si annulla, la funzione è caratterizzata da una zona piatta, un *plateau* (*vanishing gradient*). Se invece di una regione piatta, in b c'è un minimo locale

Se invece di una regione piatta, in b c'è un minimo locale, w non può superare il massimo locale nel punto c e rimane bloccato in b .

In entrambi i casi non può raggiungere il minimo locale in d .

Simili situazioni si possono verificare nelle superfici multidimensionali. Specialmente nei punti sella dove il gradiente è zero, ma il punto non è un minimo oppure un massimo.



Importanza del Learning rate

Valori bassi di η

- possono far sì che sia necessario un numero elevato di passi prima che l'allenamento sia completato.




- possono far sì che i pesi rimangano bloccati in un minimo locale, che è sub-optimal se confrontato con il global minimum.




Valori alti di η

Valori alti di learning rate permettono di mitigare questi problemi passando oltre i minimi locali e raggiungendo il minimo in numero limitato di passi.



i pesi possono anche finire per superare il minimo target




Queste osservazioni fanno intuire che la scelta del learning rate è cruciale ed in pratica può richiedere molta sperimentazione per scoprire quale può essere il valore ottimale del learning rate.

Consideriamo adesso una lossy del tipo

$$f(w_1, w_2) = 0.1 w_1^2 + 2 w_2^2$$

- ha il suo minimo in $(0,0)$.
- è *molto* piatta nella direzione di w_1 .
-

- $\nabla f(w_1, w_2) = \begin{bmatrix} \frac{\partial f(w_1, w_2)}{\partial w_1} \\ \frac{\partial f(w_1, w_2)}{\partial w_2} \end{bmatrix} = \begin{bmatrix} 0.2 w_1 \\ 4 w_2 \end{bmatrix}$



Vediamo cosa succede quando eseguiamo la discesa del gradiente per calcolarne il minimo. Scegliamo un learning rate di $\eta = 0.4$.

$$\mathbf{w}_1^{(0)} = -5, \mathbf{w}_2^{(0)} = -2,$$

$$f(\mathbf{w}_1^{(0)}, \mathbf{w}_2^{(0)}) = 10.5$$

$$\mathbf{w}_1^{(1)} = \mathbf{w}_1^{(0)} - \eta \frac{\partial f}{\partial \mathbf{w}_1}(\mathbf{w}_1^{(0)}, \mathbf{w}_2^{(0)}) =$$

$$= -5 - 0.4(0.2 \cdot -5) = -4.6$$

$$\mathbf{w}_2^{(1)} = \mathbf{w}_2^{(0)} - \eta \frac{\partial f}{\partial \mathbf{w}_2}(\mathbf{w}_1^{(0)}, \mathbf{w}_2^{(0)}) =$$


$$-2 - 0.4(4 \cdot (-2)) = 1.2$$

$$\mathbf{w}_1^{(1)} = -4.6, \mathbf{w}_2^{(1)} = 1.2,$$

$$f(\mathbf{w}_1^{(1)}, \mathbf{w}_2^{(1)}) = 4.996$$

$$\mathbf{w}_1^{(2)} = -4.2, \mathbf{w}_2^{(2)} = -0.7,$$

$$f(\mathbf{w}_1^{(2)}, \mathbf{w}_2^{(2)}) = 2.7$$



Per come è definita la funzione costo $f(w_1, w_2)$ il gradiente nella direzione w_2 è molto più alto e cambia molto più rapidamente rispetto alla direzione orizzontale.

Si possono verificare due situazioni in base alla scelta del learning rate:

- Se scegliamo un learning rate basso la soluzione non diverge nella direzione verticale w_2 , ma c'è una lenta convergenza nella direzione orizzontale w_1 .
- Con un elevato learning rate progrediamo rapidamente nella direzione orizzontale w_1 , ma c'è divergenza nella direzione verticale w_2
- .

Dopo 20 epoche w_1 : -0.943467, w_2 : -0.000073

Per risolvere questi problemi si introduce **il gradient descent con momentum.**

Gradient Descent con Momentum

Il Gradient Descent (Discesa del gradiente) è un algoritmo di ottimizzazione ampiamente utilizzato per addestrare reti neurali e altri modelli di apprendimento automatico.

Tuttavia, l'aggiornamento dei parametri durante la discesa del gradiente può essere lento e presentare oscillazioni, soprattutto per funzioni di costo con curvature dolci o valli poco profonde.

Momentum è una tecnica utilizzata per accelerare la convergenza e ridurre le oscillazioni durante l'allenamento con Gradient Descent.

Formula di aggiornamento dei pesi :

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \eta \mathbf{v}_k$$

$\mathbf{v}_k = \beta \mathbf{v}_{k-1} + \nabla \mathcal{C}(\mathbf{w}_k)$ β prende il nome di **momentum** e può variare tra 0 ed 1. \mathbf{v}_0 viene inizializzato a zero.

Se si pone $\beta = 0$, si ricade nel **classico metodo del gradiente**. Un valore appropriato è tra 0.8 e 0.9.

Analizziamo il termine $v_k = \beta v_{k-1} + \nabla C(w_k)$

$$v_1 = \beta v_0 + \nabla C(w_1)$$

$$v_2 = \beta v_1 + \nabla C(w_2)$$

$$v_2 = \beta(\beta v_0 + \nabla C(w_1)) + \nabla C(w_2) = \beta^2 v_0 + \beta \nabla C(w_1) + \nabla C(w_2)$$

$$\begin{aligned} v_3 &= \beta v_2 + \nabla C(w_3) = \beta(\beta^2 v_0 + \beta \nabla C(w_1) + \nabla C(w_2)) + \nabla C(w_3) \\ &= \beta^3 v_0 + \beta^2 \nabla C(w_1) + \beta \nabla C(w_2) + \nabla C(w_3) \end{aligned}$$

$$v_k = \beta^k v_0 + \beta^{k-1} \nabla C(w_1) \dots + \beta \nabla C(w_{k-1}) + \beta^0 \nabla C(w_k)$$

Posto $v_0 = 0$


$$v_k = \sum_{j=1}^k \beta^{k-j} \nabla C(w_j)$$


Si basa sullo stesso concetto di **momento**, *quantità di moto in fisica*. Un classico esempio del concetto è una palla che rotola giù da una collina che raccoglie abbastanza slancio per superare una regione di altipiano e raggiungere un minimo globale invece di rimanere bloccata in un minimo locale.

Il termine momento aumenta le dimensioni degli aggiornamenti quando i gradienti puntano nella stessa direzione mentre riduce le dimensioni degli aggiornamenti quando i gradienti cambiano direzione.

In questo modo si ottiene una più veloce convergenza e si riduce l'oscillazione.


In questo modo la scelta del learning rate è meno cruciale poiché la procedura di training si adatta alla particolare loss function.





- Tornando al nostro esempio, il metodo del gradiente con momento produrrà le seguenti iterazioni:

-
- nella direzione w_1 il metodo del gradiente con momento accumulerà gradienti ben allineati, aumentando così la distanza che percorriamo ad ogni passo.
 - Al contrario, nella direzione w_2 in cui i gradienti sono oscillanti, l'accumulo dei gradienti ridurrà la dimensione del passo a causa delle oscillazioni che si annullano a vicenda.



Direzione w_1 :

Gradienti ben allineati: Se i gradienti nella direzione w_1 sono ben allineati, l'accumulo di gradienti con Momentum amplifica la loro direzione, aumentando la distanza percorsa ad ogni passo.

Il termine di momentum conserva la "memoria" dei gradienti passati, favorendo la continuità del movimento nella stessa direzione. Se i gradienti sono allineati, l'accumulo li rafforza, permettendo al modello di avanzare più rapidamente lungo questa traiettoria.

Direzione w_2 :


Gradienti oscillanti: Se i gradienti nella direzione w_2 oscillano, l'accumulo di gradienti con Momentum tende a ridurre la dimensione del passo, smorzando le oscillazioni.

Il termine di momentum media i gradienti passati, attenuando l'effetto di quelli che si annullano a vicenda a causa delle oscillazioni. Questo aiuta a stabilizzare il movimento e a impedire che il modello si sposti troppo in una direzione e poi torni indietro.

Learning rate adattivo

Uno degli iperparametri più difficili da regolare nelle reti neurali è il **learning rate**.

- La funzione costo diminuisce ma richiede molto più tempo per converge (**learning rate basso**, marrone)
- La funzione costo raggiunge un valore migliore di quello iniziale, ma è ancora lontano da un valore ottimale (**Learning rate alto**: viola)
- La funzione costo inizialmente diminuisce poi inizia ad aumentare (**Learning Rate molto alto**, curva blu)
- La funzione costo diminuisce costantemente fino a raggiungere il valore minimo possibile (**Learning rate buono**, curva azzurra)



Effetto di differenti learning rate sulla minimizzazione della funzione costo.

Learning Rate (LR) scheduling

La regolazione del learning rate durante l'allenamento è spesso importante tanto quanto la selezione dell'ottimizzatore

- un **Learning Rate alto è auspicabile all'inizio** poiché i pesi sono lontani dai valori per cui la loss function raggiunge il suo minimo.
- un **Learning rate basso è più appropriato nella fase finale** dell'apprendimento perché i pesi sono già vicini dai valori per cui la loss function raggiunge il suo minimo, (aumentando la possibilità di raggiungere il minimo)

Per **regolare il Learning rate** , ci sono una serie di aspetti da considerare

- **Grandezza**: se il learning rate è troppo grande, l'ottimizzazione diverge, se è troppo piccolo ci vuole troppo tempo per l'allenamento o si finisce con un risultato non ottimale
- **Tasso di decadimento**: se il Learning Rate rimane grande potremmo rimbalzare intorno al minimo senza raggiungerlo

Le tecniche di aggiornamento del learning rate cercano di regolarlo durante l'allenamento riducendolo in accordo ad uno schema predefinito.

Un LR troppo alto può portare a oscillazioni instabili e impedire alla rete di convergere verso una soluzione ottimale.

Al contrario, un LR troppo basso può rallentare eccessivamente l'allenamento e richiedere un tempo di calcolo computazionalmente costoso.

Per questo motivo, **le tecniche di decadimento del learning rate (LR decay) sono impiegate per regolare il LR durante l'allenamento.** Queste tecniche riducono gradualmente il LR nel tempo, cercando un equilibrio tra velocità di convergenza e stabilità.

Sfide nella scelta del momento giusto per il decadimento (decay)

Decidere quando e come far decadere il LR è una sfida cruciale nell'allenamento delle reti neurali. Se il decadimento avviene troppo lentamente, si rischia di sprecare tempo di calcolo con piccoli miglioramenti incrementali. Al contrario, un decadimento troppo aggressivo può raffreddare prematuramente la rete, impedendole di raggiungere il minimo globale o una soluzione ottimale.

Strategie comuni per il decadimento del learning rate:

Esistono tre tipi comuni di implementazione del decadimento del learning rate:

- **Step decay** : riduce il Learning rate iniziale η_0 di un fattore δ ogni numero predefinito di epoche s

$$\eta = \eta_0 \cdot \delta^{\lfloor \frac{n}{s} \rfloor}$$

dove η_0 e δ e s sono iperparametri e n è il numero di epoche eseguite

- Il **decadimento esponenziale** ha la forma matematica

$$\eta = \eta_0 \cdot e^{-kt}$$

dove η_0 e k sono iperparametri e t è il numero di iterazione corrente

- Il **decadimento basato sul tempo** divide il learning rate iniziale η_0 in funzione del numero di iterazioni eseguite (t)

$$\eta = \frac{\eta_0}{1 + k \cdot t}$$

dove η_0 e k sono iperparametri

L'utilizzo del warm-up per l'inizializzazione casuale dei parametri

L'inizializzazione casuale dei parametri è una tecnica comune per l'avvio dell'allenamento di una rete neurale. Tuttavia, questa tecnica può presentare alcune sfide, in particolare quando si utilizzano learning rate elevati all'inizio dell'allenamento.

Problemi con l'inizializzazione casuale e learning rate elevati:

Divergenza: Un learning rate elevato può amplificare gli errori iniziali e causare una rapida crescita dei valori dei parametri, portando alla divergenza della rete neurale.

Lentezza del progresso: Un learning rate troppo basso, necessario per evitare la divergenza, può rallentare notevolmente il progresso dell'allenamento.

Soluzione: warm-up del learning rate

Il warm-up del learning rate è una tecnica che affronta i problemi sopracitati introducendo un periodo iniziale di allenamento con un learning rate molto inferiore rispetto al valore finale desiderato. Questo periodo di **warm-up** consente alla rete di adattarsi gradualmente ai parametri iniziali casuali senza causare divergenza e prepara il terreno per un allenamento più efficiente con un learning rate più alto.


Come funziona il warm-up del learning rate:

Inizializzazione: I parametri della rete neurale vengono inizializzati casualmente.

Warm-up: Si inizia con un learning rate molto basso (ad esempio, 10 volte o 100 volte inferiore rispetto al learning rate finale desiderato).

Aumento graduale del learning rate: Durante un periodo di warm-up predefinito (ad esempio, un certo numero di iterazioni o epoche), il learning rate viene gradualmente aumentato fino a raggiungere il valore finale desiderato.

Allenamento con learning rate e decay: Una volta raggiunto il learning rate finale, si riduce con una tecnica di decay fino alla fine del processo di ottimizzazione.



(a) Learning Rate Schedule

Le regole di aggiornamento del learning rate, come il decadimento a step o esponenziale, sono ampiamente utilizzati nell'allenamento delle reti neurali. Tuttavia, presentano alcune limitazioni:

- **Manca di adattabilità:** non si adattano alle caratteristiche specifiche del modello o dei dati, richiedendo la definizione manuale di iperparametri che potrebbero non essere ottimali.
- **Aggiornamenti uniformi** applicano lo stesso learning rate a tutti i parametri della rete, non considerando la diversa importanza o velocità di convergenza di ciascun peso.
- **Inefficienza per dati sparsi:** Nei casi di dati sparsi, dove alcuni pesi interagiscono con pochi dati, un learning rate fisso può portare a un aggiornamento eccessivo di questi pesi, ostacolando la convergenza.

Metodi di aggiornamento adattivo del learning rate

Per superare queste limitazioni, sono stati sviluppati metodi di aggiornamento adattivo del learning rate che **modificano dinamicamente il learning rate per ciascun peso durante l'allenamento**. Questi metodi si basano su informazioni accumulate durante il processo di apprendimento per ottimizzare il ritmo di aggiornamento dei pesi.

Quattro metodi rappresentativi:

- 1. Adagrad:**
- 2. RMSProp**
- 3. Adadelta**
- 4. Adam:**

Adagrad

- Adagrad **adatta il Learning Rate ai parametri**, eseguendo aggiornamenti più grandi per i parametri poco frequenti e aggiornamenti più piccoli per quelli frequenti.
- Regola il tasso di apprendimento per i parametri in proporzione alla loro cronologia di aggiornamento, più aggiornamenti più decadimento

$$s_k = s_{k-1} + (\nabla C(w_k))^2$$

$$w_{k+1} = w_k - \frac{\eta}{\sqrt{s_t} + \epsilon} \nabla C(w_k)$$

Minore è il gradiente accumulato, minore sarà il valore s_k , portando a un learning rate maggiore.

Uno dei principali vantaggi è che Adagrad elimina la necessità di regolare manualmente il learning rate. Il principale punto debole è l'accumulo dei gradienti al quadrato: durante l'addestramento la somma accumulata cresce, il learning rate diminuisce diventando infinitesimamente piccolo fino a quando la rete non è più in grado di acquisire ulteriore conoscenza:

Effetti di Adagrad:

Aggiornamenti più grandi per parametri rari: I parametri che vengono aggiornati meno frequentemente hanno un accumulatore di gradienti quadrati più piccolo, risultando in un learning rate normalizzato più alto e aggiornamenti più grandi.

Aggiornamenti più piccoli per parametri frequenti: I parametri che vengono aggiornati più frequentemente hanno un accumulatore di gradienti quadrati più grande, risultando in un learning rate normalizzato più piccolo e aggiornamenti più piccoli.

Riduzione del rischio di sovrastima: Adagrad aiuta a prevenire la sovrastima dei parametri, in particolare quelli con gradienti elevati, regolando il learning rate in base alla loro storia di aggiornamento.

Vantaggi di Adagrad:

- **Adattabilità:** Adagrad si adatta automaticamente alle caratteristiche dei dati e del modello, ottimizzando il learning rate per ciascun parametro.
- **Efficienza:** Può accelerare la convergenza in alcuni casi, soprattutto per modelli con parametri rari o con gradienti elevati.
- **Robustezza:** Può essere utile per problemi di ottimizzazione con vincoli di sparsità o con dati rumorosi.

Svantaggi di Adagrad:

- **Accumulo di gradiente quadrato:** L'accumulatore di gradiente quadrato può crescere senza limiti, portando a un learning rate troppo piccolo e a una convergenza lenta o stagnante.
- **Sensibilità ai gradienti iniziali:** Può essere influenzato dai valori iniziali dei parametri, portando a prestazioni subottimali se i parametri iniziali sono mal scelti.

RMSProp

RMSProp (Root Mean Square Propagation) è un algoritmo di ottimizzazione per l'apprendimento automatico che deriva da Adagrad e ne migliora alcune limitazioni.

Come Adagrad, RMSProp **adatta il learning rate individualmente per ciascun parametro** di una rete neurale durante l'allenamento.

RMSProp è stato introdotto **per ridurre la diminuzione aggressiva** del learning rate di Adagrad

Modifica la parte di accumulo del gradiente di Adagrad con una media ponderata esponenziale dei gradienti al quadrato invece della somma dei gradienti al quadrato

$$s_k = \gamma s_{k-1} + (1 - \gamma) (\nabla C(w_k))^2$$

$$w_{k+1} = w_k - \frac{\eta}{\sqrt{s_k} + \epsilon} \nabla C(w_k)$$

Effetti di RMSProp:

- **Riduzione del decadimento aggressivo:** La media ponderata esponenziale attenua l'effetto dei gradienti passati, impedendo un decadimento troppo rapido del learning rate come può accadere con Adagrad.
- **Maggiore stabilità:** RMSProp tende ad essere più stabile di Adagrad e meno incline a oscillazioni o divergenze durante l'allenamento.
- **Convergenza più affidabile:** Può aiutare a ottenere una convergenza più affidabile e uniforme su un'ampia gamma di problemi di ottimizzazione.

Vantaggi di RMSProp:

- **Migliora la stabilità:** Rispetto ad Adagrad, RMSProp offre una maggiore stabilità e riduce il rischio di oscillazioni o divergenze.
- **Convergenza più affidabile:** Può facilitare una convergenza più uniforme e affidabile su diverse tipologie di problemi.
- **Meno sensibile ai gradienti iniziali:** È meno sensibile ai valori iniziali dei parametri rispetto ad Adagrad.

Svantaggi di RMSProp:

- **Potenziale accumulo di errore:** La media ponderata esponenziale può accumulare errori nel tempo, soprattutto per modelli con gradienti rumorosi.
- **Scelta del fattore di smorzamento:** Il fattore di smorzamento γ deve essere scelto attentamente per ottenere il miglior bilanciamento tra stabilità e velocità di convergenza.

ADADELTA

Adadelata è un'altra variante di Adagrad proposta per superare il suo principale inconveniente

Come RMSProp calcola l'accumulo del gradiente come una media ponderata esponenziale dei gradienti al quadrato ma, a differenza di RMSProp, **non richiede di impostare un learning rate** in quanto utilizza la quantità di cambiamento stessa come calibrazione per il cambiamento futuro

$$s_k = \gamma s_{k-1} + (1 - \gamma) (\nabla C(w_k))^2$$

$$\check{\nabla} C = \frac{\sqrt{\Delta w_{k-1} + \epsilon}}{\sqrt{s_k + \epsilon}} \nabla C(w_k)$$

$$w_{k+1} = w_k - \check{\nabla} C$$

$$\Delta w_k = \gamma \Delta w_{k-1} + (1 - \gamma) (\check{\nabla} C)^2$$

dove Δw_k è la media pesata esponenziale dei quadrati dei gradienti pesati. $(\check{\nabla} C)$

ADAM

L'obiettivo principale di ADAM (Adaptive Moment Estimation) è quello di combinare i vantaggi di due altri algoritmi di ottimizzazione: RMSprop e Momentum.

Utilizza la media pesata esponenziale dei gradienti ai passi precedenti, per ottenere una stima del momento del gradiente

$$v_k = \beta_1 v_{k-1} + (1 - \beta_1) \nabla C(w_k)$$

e del momento secondo del gradiente

$$s_k = \beta_2 s_{k-1} + (1 - \beta_2) (\nabla C(w_k))^2$$

Si noti che se si inizializzano $v_0 = 0$ ed $s_0 = 0$, i momenti iniziali sono "sbilanciati" all'inizio del processo di apprendimento, per compensare questo sbilanciamento si usano le seguenti normalizzazioni

$$\hat{v}_k = \frac{v_k}{1 - (\beta_1)^k} \quad \hat{s}_k = \frac{s_k}{1 - (\beta_2)^k}$$

allora l'equazione di aggiornamento diventa

$$w_{k+1} = w_k - \frac{\eta}{\sqrt{\hat{s}_k + \epsilon}} \hat{v}_k$$

il metodo ADAM adatta in modo dinamico il learning rate per ciascun parametro del modello utilizzando le stime dei momenti del primo e del secondo ordine. Questo approccio consente ad ADAM di convergere più velocemente e di essere più robusto rispetto ad altri metodi di ottimizzazione tradizionali.

In sintesi, il confronto tra i metodi di ottimizzazione visti.

1.Gradient Descent (GD):

1. È il metodo di base per l'ottimizzazione dei modelli di machine learning.
2. Richiede il calcolo del gradiente dell'intero set di dati di addestramento ad ogni iterazione, rendendolo computazionalmente costoso per grandi set di dati.
3. Può soffrire di problemi come il plateau dei gradienti o la convergenza lenta in presenza di curve di costo complesse o di minime locali.

2.Stochastic Gradient Descent (SGD):

1. Utilizza un campione casuale dal set di dati di addestramento per calcolare il gradiente ad ogni iterazione.
2. Rispetto al GD, SGD è più efficiente computazionalmente, soprattutto per grandi set di dati.
3. Tuttavia, la variabilità introdotta dall'utilizzo di un singolo campione può rendere l'ottimizzazione più rumorosa e richiedere una scelta attenta del tasso di apprendimento.

3.Mini-batch Gradient Descent:

1. È una variante di SGD in cui il gradiente viene calcolato su un piccolo sottoinsieme di campioni (mini-batch) a ogni iterazione.
2. Combina vantaggi di GD e SGD: più efficiente di GD e meno rumoroso di SGD.
3. Richiede una scelta appropriata della dimensione del mini-batch, che può influenzare la convergenza e la velocità di apprendimento.

1.Momentum-based:

1. Utilizzano un momento che tiene conto dei gradienti precedenti per accelerare la convergenza.
2. Sono particolarmente efficaci per ridurre l'effetto di oscillazioni o rumore nella direzione del gradiente.
3. Possono aiutare a superare zone di plateau e minimi locali piatti.

2.Adagrad:

1. Adatta il learning rate per ciascun parametro in base alla somma dei gradienti passati.
2. Funziona bene in presenza di sparsi gradienti o feature sparse.
3. Tuttavia, può diminuire troppo velocemente il tasso di apprendimento nel corso dell'addestramento, rendendolo inefficiente nelle fasi successive.

3.RMSprop:

1. Adatta il learning rate in base alla media mobile delle varianze dei gradienti passati.
2. Aiuta ad affrontare il problema di diminuzione eccessiva del tasso di apprendimento in Adagrad.
3. È particolarmente utile quando i parametri del modello hanno diverse scale di aggiornamento.

4.ADAM:

1. Combina le idee di RMSprop e momento per adattare il learning rate in modo individuale per ciascun parametro.
2. È efficace in diverse situazioni e spesso offre una convergenza più rapida rispetto ad altri metodi di ottimizzazione. Tuttavia, può richiedere una scelta accurata dei suoi iperparametri per ottenere prestazioni ottimali